Clase 1 de 5

Google Cloud | The LAB

El trabajo con datos y la nube

Ingeniería y Análisis de Datos en Google Cloud

UTN · Facultad Regional Rosario

6 de octubre de 2026



Juan Mantegazza

Ingeniero y Analista de Datos

Trayectoria

6+ años en datos

Empresas de producto y de servicios.

Formación

Ingeniero Industrial, UTN FRBA

Diplomado en AI & Big Data, UNICEN

Certificaciones Google Cloud

Professional Data Engineer ×2

Professional Cloud Architect

Google Cloud | The LAD

De qué se trata este curso

Construimos una plataforma de datos en Google Cloud. Empieza en la fuente y termina en una métrica.

Qué construimos

Los datos entran crudos. Pasan por capas que los ordenan. Terminan en una tabla de métricas.

Con qué

BigQuery para guardar y consultar. dbt para modelar. Git para versionar. Todo entra en el nivel gratuito.

Qué no es

No es un curso de SQL. No prepara para la certificación de Google. El SQL que usamos es básico y lo escribimos juntos.

Trabajamos sobre datos reales: viajes de taxi de Nueva York y clima.

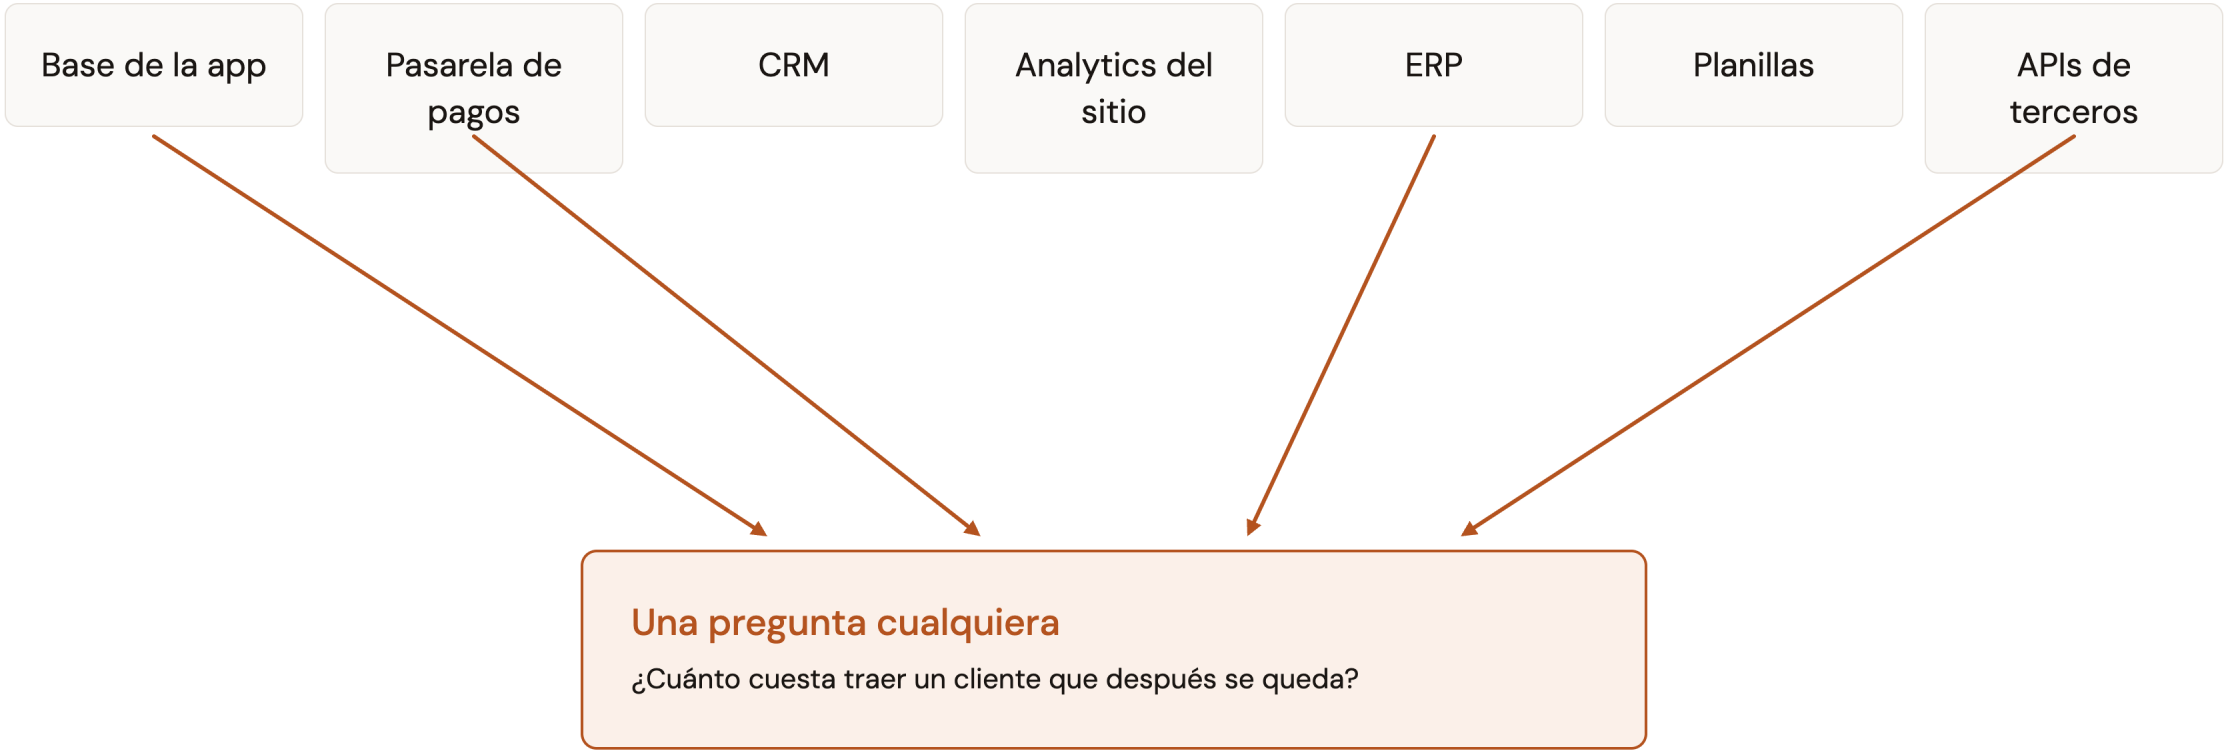
Hoy

19:00	De qué se trata el curso
19:15	El problema
19:30	Quién lo resuelve
19:45	La nube y Google Cloud
20:00	Receso
20:10	Permisos y gobierno
20:20	A la consola
20:35	El curso y el trabajo práctico

Casi ninguna organización puede responder rápido una pregunta sobre sus propios datos.

Google Cloud | The LAD

Los datos viven donde se generan



Ninguno de esos sistemas fue diseñado para responderla. Ninguno sabe que los otros existen.

¿Por qué no leemos directo de la fuente?

¿Por qué no leemos directo de la fuente?

01 Guardan cada registro entero y junto. Para sumar una columna tienen que leerlos todos.

02 Una consulta pesada frena la aplicación que están atendiendo.

03 Tienen el estado de hoy. No tienen el de hace seis meses.

04 El esquema cambia cuando el equipo de la app lo decide.

05 Una planilla o una API de terceros no tienen SQL.

El dato se copia a un data warehouse.

Un sistema cuyo único trabajo es responder preguntas sobre millones de registros.

Eso es el centro de una plataforma de datos.

Google Cloud | The LAD

Los cuatro roles

Rol	De qué es responsable	Pregunta que contesta
Data Engineer	Que el dato llegue, completo y a tiempo	¿Está el dato?
Analytics Engineer	Que el dato crudo se vuelva confiable y entendible	¿Qué significa?
Data Analyst	Que el dato se convierta en una decisión	¿Qué está pasando?
Data Scientist	Que el dato explique causas y anticipe lo que viene	¿Qué va a pasar?

Este curso se para en las dos primeras filas.

Un día de un ingeniero de datos

Lo que se cree

- Diseñar arquitecturas
- Elegir tecnologías nuevas
- Optimizar consultas

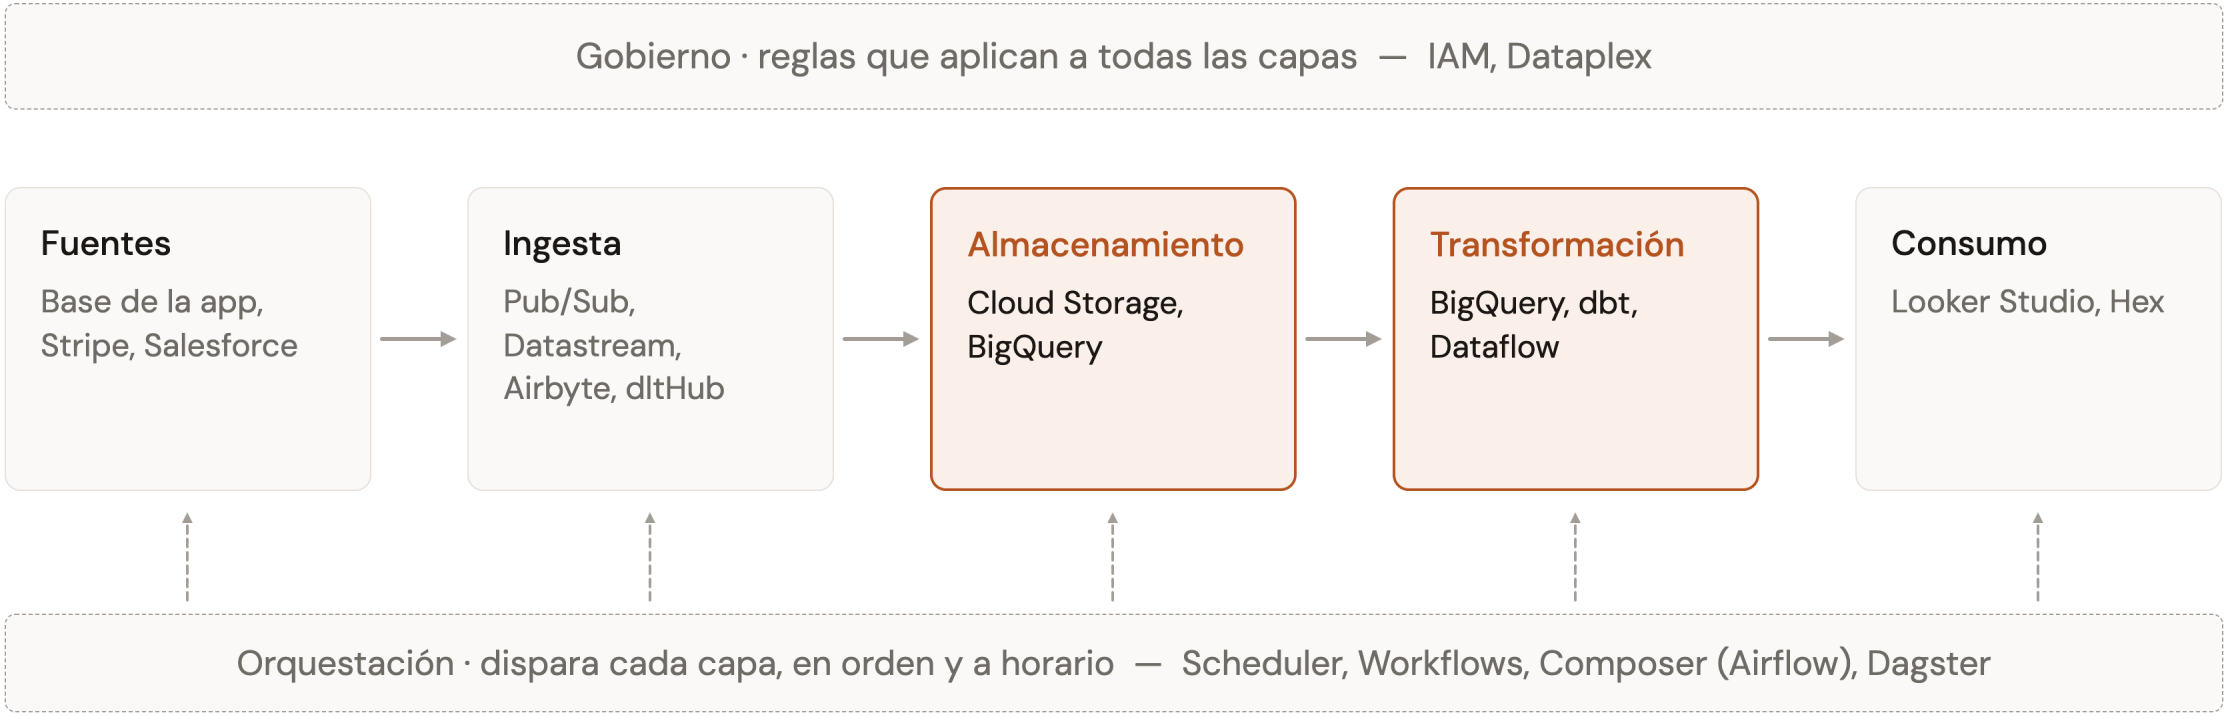
Lo que pasa

- Por qué falló el proceso de anoche
- Qué significa un campo sin documentar
- Qué cuenta como cliente activo
- Por qué el número cambió

Del BI tradicional a Google Cloud

Dimensión	Stack tradicional de BI	Google Cloud	Qué se gana
Almacenamiento y cómputo	Acoplados en un servidor dimensionado por compra	Desacoplados. BigQuery asigna cómputo por consulta	Escala sin compra previa
Latencia del dato	Proceso ETL nocturno sobre ventana fija	Ingesta continua o por lotes frecuentes	Decisiones sobre el día en curso
Modelo semántico	Definido dentro del cubo, sin versionado ni pruebas	Definido en SQL versionado, con pruebas y linaje	La definición se revisa como código
Modelo de costo	Inversión sobre la capacidad instalada	Gasto sobre el volumen consultado	Se paga el uso

Una plataforma de datos, por capas



En este curso nos centramos en almacenamiento y transformación. Las demás capas se explican para entender el mapa completo.

10:00

Receso

El proyecto, y quién puede hacer qué

En Google Cloud el proyecto es la unidad de facturación y de permisos. Es lo que van a crear hoy.

Identidad
Persona, grupo o cuenta de servicio

→ tiene →

Rol
Un paquete de permisos con nombre

→ sobre →

Recurso
Y todo lo que tenga adentro

Lo que se otorga arriba se hereda hacia abajo

Proyecto → hereda → **Dataset** → hereda → **Tabla**

Por eso alguien termina viendo algo que nadie le dio explícitamente.

Ejemplo · el rol BigQuery Data Viewer para ana@empresa.com

Otorgado sobre el **proyecto**, lee todos los datasets, también los que se creen mañana.

Otorgado sobre el dataset **ventas**, lee solo sus tablas, incluida **ventas.pedidos_2027**, que todavía no existe.

Gobierno de datos

Las reglas sobre el dato

Acceso	Calidad	Linaje	Privacidad	Propiedad
¿Quién lo autoriza?	¿Está bien el dato?	¿De dónde salió?	¿Qué es personal?	¿Quién es dueño?

Ejemplo · las cinco preguntas sobre una sola tabla

ventas_mensuales: quién autorizó el acceso de Marketing, si los totales cuadran con el origen, de qué modelos salió, si incluye el documento del cliente, y a quién se le reclama cuando el número está mal.

Lo retomamos en la clase 5.

A la consola

La consola por dentro

Crear un proyecto y activar BigQuery

Dónde se ven los permisos

La primera consulta

Google Cloud | The LAD

Las cinco clases

01	El trabajo con datos y la nube	Qué es una plataforma y cómo se organiza Google Cloud
02	Arquitectura y diseño	Cómo funciona BigQuery por dentro: particionado y costo
03	Transformación y capa de métricas	Modelado, capas e intro a dbt
04	dbt en la práctica y calidad de datos	Demo de dbt, tests y métricas
05	Operación, gobierno e ingesta	Que corra solo, que no se rompa y que tenga reglas

El trabajo práctico se resuelve con las clases 1 a 4.

Dos certificados

Asistente

80 % de asistencia

Técnico

80 % de asistencia
+ trabajo práctico aprobado

El trabajo práctico

01

Traer el dato

Dos CSV, viajes de taxi de Nueva York y clima, cargados en **tp_raw** con su schema en JSON.

02

Modelarlo

Staging y marts en dbt, con tests y **partition_by** y **cluster_by** en el config().

03

Responder

Cuatro preguntas en RESPUESTAS.md. Cada una tiene una respuesta numérica única.

04

Justificarlo

Un README con una decisión de diseño, la alternativa descartada y el motivo.

Entrega · miércoles 4/11, 23:59 · sin reentrega

Resultado · lunes 9 de noviembre

Zip del repo git a google@thelabtech.com.ar

Cómo se corrige

Criterio	Se cumple si
Estructura	Están todos los archivos obligatorios de la entrega
Capas	Los marts llegan al raw solo a través de staging
Pruebas	Al menos tres, con una prueba singular propia escrita en SQL
Diseño físico	partition_by y cluster_by declarados en el config() y justificados en el README
Respuestas	Los cuatro números coinciden con los correctos
Justificación	El README explica una decisión, la alternativa descartada y el motivo

Para el martes que viene

Obligatorio

Mandar la salida de dbt debug

En GitHub Discussions, los que todavía no la mandaron.

Recomendado

Leer la consigna del TP

Y correr las consultas de práctica que quedan en el repositorio.

Clase 2 · Arquitectura y diseño

13 de octubre, 19:00

Gracias

Preguntas

Google Cloud | The LAD